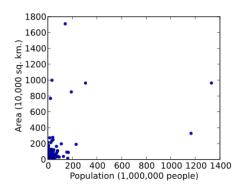
01. Fiche d'auto-évaluation

May 6, 2021

• Regardez le graphe ci-dessous¹



Pouvez-vous voir clairement s'il y a une dépendance entre "Population" et "Area"? Y a-t-il des transformations qui peuvent aider à montrer plus clairement la possible dépendance? Si oui, est-il mieux d'appliquer telle transformation à l'axe des x, des y, ou aux deux?

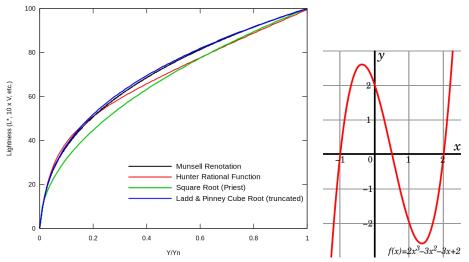
 $\bullet\,$ Regardez les deux graphes ci-dessous 2 3

 $^{^1{\}rm Attribution~Skbkekas},~{\rm CC~BY\text{-}SA}~3.0~< http://creativecommons.org/licenses/by-sa/3.0/>, via Wikimedia Commons$

²Attribution: Creative Commons Attribution-ShareAlike 2.5 , https://en.wikipedia.org/wiki/File:Lightness_approximations.svg

³Attribution: Krishnavedala, CC BY-SA 3.0 https://creativecommons.org/licenses/by-shareAlike

³Attribution: Krishnavedala, CC BY-SA 3.0 https://creativecommons.org/licenses/by-sa/3.0, via Wikimedia Commons



Pour chaque graphe, dites s'il y a une dépendance entre les x et les y. Si on calcule le coefficient de corrélation de Pearson, sera-t-il positif négatif ou zéro?

- Imaginez de travailler avec un jeu de donnée, dont une caractéristique peut prendre 4 valeurs. Vous avez deux façons de l'encoder: (i) transformer les valeurs en 0,1,2,3 ou (ii) appliquer le one-hot encoding. Dans quel cas faut-il choisir l'un ou l'autre?
- Imaginez de travailler avec un jeu de donnée de 200 colonnes. Une colonne a 0.1% de valeurs manquantes. Une autre colonne a 30% de valeurs manquantes. Quel type de traitement (pre-processing) peut-on appliquer au jeu de données avant d'appliquer d'autres méthodes supervisées ou non-supervisées? [Regardez le code du notebook concernant le pre-processing]
- Imaginez qu'une de vos colonnes aie les valeurs suivantes: very bad, bad, medium, good, very good, excellent, no-opinion. Comment peut-on transformer la colonnes pour permettre aux méthodes d'apprentissage automatique de l'utiliser?
- Écrivez les formules de la variance d'une caractéristique, l'écart type (standard deviation), le coefficient de corrélation de Pearson.
- Expliquez comment on construit une boite à moustache (boxplot) et la signification de toutes les lignes qu'on y retrouve.
- Expliquez comment on calcule le 35me percentile.

2